

Assignment #1

Adaline SGD 員工特徵分類

機器學習實作系列 第 2 週 : Python 基礎

姓名：陳欣怡

資料集：tech_employees.csv (300 筆員工樣本)

模型：自行實作 Adaline SGD (未使用 scikit-learn)

一、作業說明

目的

使用 Adaline SGD 分類模型，測試不同特徵組合，觀察哪一項能力指標對科技公司篩選「優秀員工」最具鑑別度。作業明確要求不使用 scikit-learn，訓練演算法（權重更新、損失計算）必須自己實作。

資料集：tech_employees.csv

- Language_Skill：語文能力，float，範圍 [0.0, 5.0]
- Math_Skill：數理能力，int，範圍 [0, 100]
- Coding_Skill：程式能力，int，範圍 [1, 10]
- Health_Condition：健康條件，float，範圍 [-1.0, 1.0]
- Performance_Label：標籤，0 = 普通、1 = 優秀

任務需求

- 資料切分：依原始順序切分，前 200 筆訓練、後 100 筆測試（不隨機切分）
- 特徵組合：4 選 2 共 6 組，再加上「全部 4 個特徵」一組，共訓練 7 個模型
- 訓練技巧：標準化、隨機打散（shuffle）、固定 / 自適應學習率、調整訓練輪次
- 關鍵限制：標準化的平均值與標準差只能用訓練集計算，避免資料洩漏

二、數學觀念

1. 線性代數 — net input (超平面)

$$z = \mathbf{w} \cdot \mathbf{x} + b = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b$$

2. 統計學 — 標準化 (Z-score)

$$z = \frac{x - \mu}{\sigma}$$

(μ 、 σ 僅以訓練集計算，再套用到訓練集與測試集)

3. 微積分 — 損失函數與梯度下降

$$L = (y - \hat{y})^2$$

$$w \leftarrow w + \eta \cdot 2x(y - \hat{y}), \quad b \leftarrow b + \eta \cdot 2(y - \hat{y})$$

SGD 的「S」代表每次只用一筆樣本估計梯度 (而非全部資料的 Batch GD)。

4. 自適應學習率

$$\eta_t = \frac{\eta_0}{1 + \alpha t}$$

隨 epoch t 遞增而遞減，訓練前期步伐大、後期步伐小，穩定收斂。

5. 分類決策 — 閾值函數

$$\hat{y} = 1 \text{ 若 } z \geq 0.5; \text{ 否則 } \hat{y} = 0$$

$z = 0.5$ 這條界線即決策邊界方程式 $\mathbf{w} \cdot \mathbf{x} + b = 0.5$

6. 正確率

$$\text{Accuracy} = \frac{n_{\text{correct}}}{n_{\text{total}}}$$

n_{correct} ：預測正確的測試筆數； n_{total} ：測試集總筆數 (100)

三、訓練與評估流程

- 1. 讀入 tech_employees.csv，依原始順序切分前 200 筆 Train / 後 100 筆 Test
- 2. 迴圈依序處理 7 種特徵組合 (4 選 2 共 6 組 + 全部 4 特徵 1 組)
- 3. 標準化：以 Train 計算 mean / std，並套用同一組統計值到 Train 與 Test
- 4. AdalineSGD.fit：每個 epoch 重新打散資料，可選自適應學習率
- 5. predict(Test)，計算 Accuracy，並記錄該組合的 losses_ (每個 epoch 平均損失)
- 6. 7 種組合跑完後，依 Accuracy 高到低排序，輸出 assignment1_results.txt
- 7. 取正確率最佳的組合，重新對比「固定學習率」與「自適應學習率」兩版本
- 8. 針對每個雙特徵組合畫決策邊界圖，彙整成 6 張子圖
- 9. 疊圖 7 條 loss 收斂曲線，觀察各組合訓練穩定度

四、預期結果 1：特徵組合正確率排序

Majority-class baseline：0.51 (作為檢驗模型是否真的學到東西的對照基準)

特徵組合	測試正確率
Math_Skill & Coding_Skill	0.84
All Four Features	0.83
Language_Skill & Coding_Skill	0.79
Coding_Skill & Health_Condition	0.75
Language_Skill & Math_Skill	0.61
Language_Skill & Health_Condition	0.61
Math_Skill & Health_Condition	0.61


各特徵平均鑑別度 (依包含該特徵之組合平均正確率)

特徵	平均正確率
Coding_Skill	0.80
Math_Skill	0.72
Language_Skill	0.71
Health_Condition	0.70

結論


Coding_Skill (程式能力) 鑑別度最高，Math_Skill (數理能力) 次之；最佳單一組合為 Math_Skill & Coding_Skill，測試正確率 0.84，與使用全部 4 個特徵 (0.83) 相當，顯示程式能力與數理能力已足以掌握「優秀員工」的主要判別資訊。

五、預期結果 2：決策邊界視覺化




assignment1_decision_boundaries.png — 6 種雙特徵組合的決策邊界區域，與對應測試集樣本分佈疊圖。色塊分界線即模型學到的線性決策邊界。

六、Loss 收斂曲線



assignment1_loss_curves.png — 7 種特徵組合的訓練 loss (平均平方誤差) 隨 epoch 收斂曲線疊圖。Math_Skill & Coding_Skill 與全部 4 特徵組合收斂至最低 loss，與正確率最高吻合。

七、固定學習率 vs 自適應學習率



assignment1_adaptive_vs_fixed.png — 以正確率最高的組合 (Math_Skill & Coding_Skill) 為代表，固定學習率 (eta=0.01) 測試正確率 0.81，自適應學習率測試正確率 0.84，且訓練中後段 loss 更低、更穩定。

八、總結

本作業從零實作 Adaline SGD 分類器 (未使用 scikit-learn) , 完成資料切分、標準化 (避免資料洩漏) 、7 種特徵組合訓練與比較、決策邊界視覺化、loss 收斂曲線分析, 以及固定 / 自適應學習率對比。

主要發現

- 程式能力 (Coding_Skill) 是預測「優秀員工」鑑別度最高的單一特徵
- Math_Skill & Coding_Skill 雙特徵組合 (0.84) 已逼近使用全部特徵的表現 (0.83)
- 自適應學習率相較固定學習率提升測試正確率 (0.81 $\rightarrow$ 0.84) , 且訓練更穩定
- 所有結果皆經過複驗 (詳見 verification_checklist.md) , 數值與圖表可重現