

Assignment #2

Logistic Regression 晶圓驗收分類

機器學習實作系列 第 5 週 : Logistic Regression

姓名：陳欣怡 學號：515661055

資料集：wat_train.csv (15 筆) / wat_test.csv (5 筆)

模型：自行實作 Logistic Regression (未使用 scikit-learn)

一、作業說明

目的

使用自行實作的 Logistic Regression 分類模型，依氧化層厚度偏差與微量金屬污染度，預測晶圓在驗收測試中為「合格 (Pass) 」或「不合格 (Fail) 」，並輸出每筆晶圓的通過機率。

資料集：wat_train.csv / wat_test.csv

- wat_train.csv：15 筆歷史晶圓資料
- x_1 ：氧化層厚度偏差 (Å)，目標值為 0
- x_2 ：微量金屬污染度 (ppm)，數值越高越容易失效
- y ：晶圓狀態，1 = Pass、0 = Fail
- wat_test.csv：5 筆待驗收晶圓資料，欄位為 Wafer ID、 x_1 、 x_2

任務需求

- 不使用 scikit-learn，自行實作 sigmoid、binary cross-entropy 與梯度下降
- 比較 x_1 、 $|x_1|$ 、 x_1^2 三種特徵表示
- 僅以訓練集計算標準化統計值，再套用至待驗收資料
- 比較不同學習率 η ，繪製 Loss 曲線與決策邊界
- 以 DataFrame 格式輸出通過機率及 Pass / Fail 結果

二、數學觀念

1. 特徵工程

x_1 的正負號代表偏差方向，但製程風險取決於偏差幅度，因此比較三種特徵表示 $\phi(x_1)$ ，並與 x_2 組成特徵向量 $\mathbf{x}$ ：

$$\phi(x_1) \in \{x_1, |x_1|, x_1^2\}, \quad \mathbf{x} = (\phi(x_1), x_2)$$

2. 標準化 (Z-score)

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

μ_{train} 與 σ_{train} 僅由訓練資料計算；待驗收資料只套用相同統計值，避免資料洩漏。

3. Logistic Regression

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = \mathbf{w}^\top \mathbf{x} + b$$

當 $p \geq 0.5$ 時預測為 Pass，否則預測為 Fail； p 同時作為晶圓的通過機率。

4. Binary Cross-Entropy 與梯度下降

$$J(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{1}{n} \sum_{i=1}^n (p_i - y_i) \mathbf{x}_i, \quad b \leftarrow b - \eta \frac{1}{n} \sum_{i=1}^n (p_i - y_i)$$

每個 epoch 使用全部 $n = 15$ 筆訓練資料計算梯度 (full-batch)，以學習率 η 更新 $\mathbf{w}$ 與 b ，使 J 下降。

5. 正確率

$$\text{Accuracy} = \frac{n_{\text{correct}}}{n_{\text{total}}}$$

n_{total} ：訓練集總筆數 (15)。

三、訓練與評估流程

- 1. 讀取 wat_train.csv 與 wat_test.csv，驗證欄位、缺失值與標籤
- 2. 分別建立 x_1 、 $|x_1|$ 、 x_1^2 三種特徵資料
- 3. 僅用 Train 計算 μ / σ ，將相同統計值套用到 Train 與 Test
- 4. 將 w 與 b 固定初始化為 0，確保結果可重現
- 5. 分別以 $\eta = 0.01$ 、 0.10 、 0.30 訓練 1,000 epochs
- 6. 比較訓練正確率、初始 loss、最終 loss 與收斂曲線
- 7. 選用 $|x_1|$ 、 x_2 與 $\eta = 0.3$ 的模型
- 8. 產生 Loss vs. Epochs 與決策邊界圖
- 9. 預測 5 筆晶圓的通過機率，輸出 DataFrame、CSV 與文字結果

關鍵限制

標準化的平均值與標準差只能用訓練集計算，避免資料洩漏；權重固定由零初始化且流程中無任何隨機步驟，因此每次執行的結果完全一致。

四、特徵轉換與學習率比較

所有模型皆訓練 1,000 epochs；正確率與 loss 均以 15 筆訓練資料計算。


特徵轉換	學習率 η	訓練正確率	初始 Loss	最終 Loss
x_1	0.01	73.33%	0.693147	0.514383
x_1	0.10	73.33%	0.693147	0.497988
x_1	0.30	73.33%	0.693147	0.497987
$ x_1 $	0.01	100.00%	0.693147	0.244851
$ x_1 $	0.10	100.00%	0.693147	0.091491
$ x_1 $	0.30	100.00%	0.693147	0.064767
x_1^2	0.01	93.33%	0.693147	0.246942
x_1^2	0.10	100.00%	0.693147	0.079437
x_1^2	0.30	100.00%	0.693147	0.047711

結論

原始 x_1 因正、負偏差互相抵銷，最高訓練正確率僅 73.33%。 $|x_1|$ 與 x_1^2 都能表達偏差幅度並達到 100%；最終選擇物理意義較直觀、且能重現題目參考輸出的 $|x_1|$ 。 $\eta=0.3$ 收斂最快且未發散。

五、決策邊界視覺化


以最終模型 ($|x_1|$ 、 x_2 、 $\eta=0.3$) 繪製決策邊界。



assignment2_decision_boundary.png — 使用 $|x_1|$ 與 x_2 的決策邊界。藍色區域預測為 Pass、紅色區域預測為 Fail；15 筆訓練樣本皆位於正確區域，訓練正確率為 100%。

六、Loss 收斂曲線

九組特徵轉換 / 學習率組合的 binary cross-entropy 隨 epoch 變化。



assignment2_loss_curves.png — 原始 x_1 最終停留在約 0.498； $|x_1|$ 與 x_1^2 的 loss 持續下降。 $\eta=0.3$ 在本資料上收斂最快。

觀察

Loss 曲線可確認訓練是否收斂，但只有訓練資料，無法據此判斷過擬合或泛化能力；第八、九節以留一交叉驗證補做這項檢驗。

七、待驗收結果

以最終模型預測 5 筆全新晶圓；分類閾值為 $p \geq 0.5$ 。

Wafer ID	x_1	x_2	$ x_1 $	通過機率 p	結果
Wafer A	-1.1	0.9	1.1	99.65%	Pass
Wafer B	4.5	0.3	4.5	4.91%	Fail
Wafer C	0.0	4.8	0.0	0.06%	Fail
Wafer D	-2.2	1.9	2.2	9.55%	Fail
Wafer E	0.3	0.5	0.3	100.00%	Pass

主要發現

- 偏差幅度 $|x_1|$ 比帶號偏差更具鑑別度，訓練正確率由 73.33% 提升至 100%
- Wafer A 與 Wafer E 的偏差幅度小且污染度低，判定為 Pass
- Wafer B 偏差幅度達 4.5、Wafer C 污染度達 4.8，皆判定為 Fail
- 五筆預測機率與題目投影片的參考輸出完全一致

八、改善空間討論（一）：訓練輪次與正則化

訓練集僅 15 筆、待驗收資料沒有標籤，無法另外切出驗證集。以下以留一交叉驗證（LOO）估計泛化能力：每折以 14 筆重新計算標準化統計值並訓練，預測被留下的 1 筆，15 折合計。待驗收晶圓的機率只作觀察，不用於挑選設定。標示 ← 者為繳交版本。

訓練輪次：loss 收斂不等於模型變好

Epochs	訓練正確率	最終 Loss	$\ \mathbf{w}\ _2$	LOO 正確率	LOO log-loss	Wafer D _p
100	100.00%	0.1455	3.29	86.67%	0.1942	26.38%
300	100.00%	0.0947	4.93	86.67%	0.1691	16.67%
1,000 ←	100.00%	0.0648	7.34	86.67%	0.2007	9.55%
3,000	100.00%	0.0421	10.96	86.67%	0.2621	4.77%
10,000	100.00%	0.0194	17.68	86.67%	0.3518	1.20%

訓練資料在 $|x_1|-x_2$ 平面上線性可分，binary cross-entropy 沒有有限的最小值：epochs 越多，loss 持續下降、 $\|\mathbf{w}\|_2$ 由 3.29 增至 17.68，但 LOO 正確率始終是 86.67%；LOO log-loss 在 300 epochs 最低（0.169），之後反而升到 0.352，Wafer D 的通過機率也從 26.38% 一路壓到 1.20%。這正是題目投影片提醒的情況：loss 收斂只代表權重還在變大、模型對自己越來越有信心，不代表分類能力提升。

L2 正則化：限制權重大小

$$J_\lambda(\mathbf{w}, b) = J(\mathbf{w}, b) + \frac{\lambda}{2n} \|\mathbf{w}\|_2^2$$

λ	訓練正確率	最終 Loss	$\ \mathbf{w}\ _2$	LOO 正確率	LOO log-loss	Wafer D _p
0 ←	100.00%	0.0648	7.34	86.67%	0.2007	9.55%
0.1	100.00%	0.1119	4.18	86.67%	0.1818	19.21%
1	100.00%	0.2592	1.80	86.67%	0.3209	34.92%
10	93.33%	0.5242	0.46	86.67%	0.5947	44.63%

$\lambda = 0.1$ 把 $\|\mathbf{w}\|_2$ 壓回 4.18，LOO log-loss 由 0.201 降至 0.182，LOO 正確率不變； $\lambda \geq 1$ 開始欠擬合， $\lambda = 10$ 連訓練正確率都掉到 93.33%。

九、改善空間討論（二）：特徵組合與最終取捨

特徵組合（皆為 $\eta = 0.3$ 、1,000 epochs、 $\lambda = 0$ ）

特徵組合	訓練正確率	LOO 正確率	LOO log-loss	Wafer B p	Wafer D p
x_1 、 x_2	73.33%	66.67%	1.0684	87.32%	31.68%
$ x_1 $ 、 $x_2 \leftarrow$	100.00%	86.67%	0.2007	4.91%	9.55%
x_1^2 、 x_2	100.00%	86.67%	0.1696	0.65%	22.36%
$ x_1 $ 、 x_1^2 、 x_2	100.00%	86.67%	0.1981	1.14%	14.35%

除原始 x_1 （LOO 正確率 66.67%）外，三種組合的 LOO 正確率都是 86.67%，且誤判的始終是同 2 筆：(1.5, 1.8)（實際 Pass，LOO 機率 28.94%）、(-1, 2.5)（實際 Fail，LOO 機率 77.17%），即第五節決策邊界圖中最貼近邊界的兩點；任何設定都無法同時把這兩筆分對。 x_1^2 的 LOO log-loss 最低（0.170），但它把 Wafer D 的機率從 9.55% 推到 22.36%、Wafer B 從 4.91% 壓到 0.65%：五筆分類結果不變，但置信度差異明顯；並列 $|x_1|$ 與 x_1^2 則無額外好處。

為何維持繳交版本的設定

- 所有調整都沒有改變 LOO 正確率；改變的只有置信度（log-loss）
- log-loss 的差距（0.17–0.20）在 15 筆資料下約等於一筆樣本的機率變動，不足以據此換設定
- 以 LOO 為準最值得採用的是 $\lambda = 0.1$ 或 x_1^2 ，但兩者都會使五筆機率偏離题目的參考輸出
- 本作業的目的是正確實作流程並重現參考結果，故維持 $|x_1|$ 、 $\eta = 0.3$ 、1,000 epochs、 $\lambda = 0$
- 若用於實務，建議加入 $\lambda \approx 0.1$ 或提早停止（約 300 epochs），避免輸出過度自信的機率

十、總結

本作業從零實作 Logistic Regression (未使用 scikit-learn)，完成資料驗證、特徵工程、標準化、梯度下降訓練、學習率比較、決策邊界與 loss 曲線視覺化，並輸出 5 筆待驗收晶圓的通過機率與 Pass / Fail 結果。

驗收項目對照

驗收項目	規定	實際結果
函式庫限制	不使用 scikit-learn	sigmoid、BCE、GD 皆手刻
特徵工程	考慮 $ x_1 $ 或 x_1^2	三種表示皆比較，採用 $ x_1 $
特徵縮放	統計值只能來自訓練集	Standardizer 僅 fit 訓練集
學習率	嘗試不同學習率	$\eta = 0.01$ 、 0.1 、 0.3 共九組
預期結果 1	Loss 曲線與決策邊界圖	兩張圖皆已產生
預期結果 2	DataFrame 輸出機率與結果	五筆與投影片範例完全一致

主要發現

- 偏差幅度 $|x_1|$ 是關鍵特徵：訓練正確率 73.33% $\rightarrow$ 100%，LOO 正確率 66.67% $\rightarrow$ 86.67%
- 資料線性可分時 loss 會無限下降，epochs 越多只是權重越大、機率越極端 (第八節)
- L2 正則化或提早停止能改善置信度，但 LOO 正確率不變，故繳交版本維持原設定 (第九節)
- 五筆待驗收晶圓的通過機率與分類結果與題目參考輸出完全一致

繳交內容

- 05_assignment2.py：資料驗證、特徵工程、標準化、模型訓練、比較、預測與繪圖
- wat_train.csv、wat_test.csv：題目提供的 CSV 資料檔
- 執行 05_assignment2.py 會自動產生兩張圖、assignment2_predictions.csv 與 assignment2_results.txt