

Assignment #2

Logistic Regression 晶圓驗收分類

機器學習實作系列 第 5 週 : Logistic Regression

姓名：陳欣怡 學號：515661055

資料集：wat_train.csv (15 筆) / wat_test.csv (5 筆)

模型：自行實作 Logistic Regression (未使用 scikit-learn)

一、作業說明

目的

使用自行實作的 Logistic Regression 分類模型，依氧化層厚度偏差與微量金屬污染度，預測晶圓在驗收測試中為「合格 (Pass) 」或「不合格 (Fail) 」，並輸出每筆晶圓的通過機率。

資料集：wat_train.csv / wat_test.csv

- wat_train.csv：15 筆歷史晶圓資料
- x1：氧化層厚度偏差 (Å)，目標值為 0
- x2：微量金屬污染度 (ppm)，數值越高越容易失效
- y：晶圓狀態，1 = Pass、0 = Fail
- wat_test.csv：5 筆待驗收晶圓資料，欄位為 Wafer ID、x1、x2

任務需求

- 不使用 scikit-learn，自行實作 sigmoid、BCE 與梯度下降
- 比較 x1、abs(x1)、x1 ** 2 三種特徵表示
- 僅以訓練集計算標準化統計值，再套用至待驗收資料
- 比較不同學習率，繪製 Loss 曲線與決策邊界
- 以 DataFrame 格式輸出通過機率及 Pass / Fail 結果

二、數學觀念

1. 特徵工程

x_1 的正負號代表偏差方向，但製程風險取決於偏差幅度。因此比較原始 x_1 、絕對值 $\text{abs}(x_1)$ 與平方 x_1^2 三種表示。

2. 標準化 (Z-score)

$$z = \frac{x - \mu_{train}}{\sigma_{train}}$$

μ 與 σ 僅由訓練資料計算；待驗收資料只使用相同統計值進行 transform，避免資料洩漏。

3. Logistic Regression

$$p = \sigma(\mathbf{w} \cdot \mathbf{x} + b) = \frac{1}{1 + e^{-z}}$$

當 $p \geq 0.5$ 時預測為 Pass，否則預測為 Fail； p 同時作為晶圓的通過機率。

4. Binary Cross-Entropy 與梯度下降

$$\text{BCE} = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

每個 epoch 使用全部 15 筆訓練資料計算梯度，更新 weights 與 bias，使 BCE 逐步下降。

5. 正確率

$$\text{Accuracy} = \frac{n_{correct}}{n_{total}}$$

n_{total} ：訓練集總筆數 (15)。

三、訓練與評估流程

- 1. 讀取 wat_train.csv 與 wat_test.csv，驗證欄位、缺失值與標籤
- 2. 分別建立 x_1 、 $\text{abs}(x_1)$ 、 x_1^2 三種特徵資料
- 3. 僅用 Train 計算 mean / std，將相同統計值套用到 Train 與 Test
- 4. 將 weights 與 bias 固定初始化為 0，確保結果可重現
- 5. 分別以 learning rate = 0.01、0.10、0.30 訓練 1,000 epochs
- 6. 比較訓練正確率、初始 loss、最終 loss 與收斂曲線
- 7. 選用 $\text{abs}(x_1)$ 、 x_2 與 learning rate = 0.3 的模型
- 8. 產生 Loss vs. Epochs 與決策邊界圖
- 9. 預測 5 筆晶圓的通過機率，輸出 DataFrame、CSV 與文字結果

關鍵限制

標準化的平均值與標準差只能用訓練集計算，避免資料洩漏；權重固定由零初始化且流程中無任何隨機步驟，因此每次執行的結果完全一致。

四、特徵轉換與學習率比較

所有模型皆訓練 1,000 epochs ; 正確率與 loss 均以 15 筆訓練資料計算。


特徵轉換	學習率	訓練正確率	初始 Loss	最終 Loss
x1	0.01	73.33%	0.693147	0.514383
x1	0.10	73.33%	0.693147	0.497988
x1	0.30	73.33%	0.693147	0.497987
abs(x1)	0.01	100.00%	0.693147	0.244851
abs(x1)	0.10	100.00%	0.693147	0.091491
abs(x1)	0.30	100.00%	0.693147	0.064767
x1 ** 2	0.01	93.33%	0.693147	0.246942
x1 ** 2	0.10	100.00%	0.693147	0.079437
x1 ** 2	0.30	100.00%	0.693147	0.047711

結論

原始 x1 因正、負偏差互相抵銷，最高訓練正確率僅 73.33%。abs(x1) 與 x1 ** 2 都能表達偏差幅度並達到 100%；最終選擇物理意義較直觀、且能重現題目參考輸出的 abs(x1)。learning rate = 0.3 收斂最快且未發散。

五、決策邊界視覺化


以最終模型 ($\text{abs}(x_1)$ 、 x_2 、learning rate = 0.3) 繪製決策邊界。



assignment2_decision_boundary.png — 使用 $\text{abs}(x_1)$ 與 x_2 的決策邊界。藍色區域預測為 Pass、紅色區域預測為 Fail；15 筆訓練樣本皆位於正確區域，訓練正確率為 100%。

六、Loss 收斂曲線

九組特徵轉換 / 學習率組合的 BCE loss 隨 epoch 變化。



assignment2_loss_curves.png — 原始 $x1$ 最終停留在約 0.498； $\text{abs}(x1)$ 與 $x1^2$ 的 loss 持續下降。學習率 0.3 在本資料上收斂最快。

觀察

Loss 曲線可確認訓練是否收斂，但只有訓練資料，無法據此判斷過擬合或泛化能力；本作業重點為正確實作 Logistic Regression 與資料前處理流程。

七、待驗收結果

以最終模型預測 5 筆全新晶圓；分類閾值為 0.5。

Wafer ID	x1	x2	abs_x1	通過機率	結果
Wafer A	-1.1	0.9	1.1	99.65%	Pass
Wafer B	4.5	0.3	4.5	4.91%	Fail
Wafer C	0.0	4.8	0.0	0.06%	Fail
Wafer D	-2.2	1.9	2.2	9.55%	Fail
Wafer E	0.3	0.5	0.3	100.00%	Pass

結論

Wafer A 與 Wafer E 的偏差幅度小且污染度低，判定為 Pass；Wafer B 偏差幅度達 4.5、Wafer C 污染度達 4.8，皆判定為 Fail。五筆預測機率與題目投影片的參考輸出完全一致。

八、總結

本作業從零實作 Logistic Regression (未使用 scikit-learn) , 完成資料驗證、特徵工程、標準化、梯度下降訓練、學習率比較、決策邊界與 loss 曲線視覺化, 並輸出 5 筆待驗收晶圓的通過機率與 Pass / Fail 結果。

主要發現

- 偏差幅度 ($\text{abs}(x1)$) 比帶號偏差更具鑑別度, 正確率由 73.33% 提升至 100%
- learning rate = 0.3 收斂最快且未發散, 1,000 epochs 內 loss 持續下降
- Wafer A、E 判定為 Pass , Wafer B、C、D 判定為 Fail
- 所有結果皆經過複驗 (詳見 verification_checklist.md) , 數值與圖表可重現