

Assignment #3

低解析度手寫數字多類別分類

機器學習實作系列 第 7 週：模型選取與模型評估

姓名：陳欣怡 學號：515661055

資料集：sklearn.datasets.load_digits() (1797 張 8×8 灰階影像)

模型：StandardScaler → L1 特徵選取 → Logistic Regression

一、作業說明

目的

建立低解析度手寫數字 (0–9) 的多類別分類器，應用情境為光學字元辨識 (OCR)。假設字元定位與切割已經過預先處理，本作業僅負責字元辨識任務，且僅針對 0–9 之數字字元。

資料集：`sklearn.datasets.load_digits()`

- 1797 張 8×8 灰階 (grayscale) 影像
- 64 維 (像素值) 特徵，整數值範圍 [0, 16]
- 多類別標籤 0–9，共 10 類
- 資料直接由 scikit-learn 載入，無外部 CSV 檔

任務需求

- 以 Logistic Regression 作為分類器演算法
- 運用資料切分、特徵縮放、特徵選取、模型選取與模型評估
- 切分比例：80% 訓練 (用於交叉驗證)、20% 測試
- 至少淘汰 20 個以上的特徵 (即僅使用 44 個以下的像素值)
- 在測試集 (約 360 筆樣本) 上的整體正確率 (Accuracy) 達 95% 以上
- 使用 `joblib.dump()` 將訓練好的最佳模型 (指管線) 儲存成檔案

二、數學觀念

1. 多類別 Logistic Regression — Softmax

$$P(y = k | \mathbf{x}) = \frac{e^{\mathbf{w}_k \cdot \mathbf{x} + b_k}}{\sum_{j=0}^9 e^{\mathbf{w}_j \cdot \mathbf{x} + b_j}}$$

10 個類別各有一組權重；預測類別取機率最大者。

2. 標準化 (Z-score)

$$z = \frac{x - \mu}{\sigma}$$

μ 、 σ 僅以訓練集計算，再套用到測試集，避免資料洩漏。

3. 特徵選取 — L1 正則化

$$\min_{\mathbf{w}} C \sum_i L(y_i, \hat{y}_i) + \|\mathbf{w}\|_1$$

L1 懲罰會把不重要像素的權重壓到 0，因此可依各像素的權重大小排序重要性，取前 N 個作為選取結果。

4. 交叉熵損失 (多類別)

$$L = -\frac{1}{n} \sum_{i=1}^n \sum_{k=0}^9 y_{ik} \log P(y = k | \mathbf{x}_i)$$

5. 正確率

$$\text{Accuracy} = \frac{n_{\text{correct}}}{n_{\text{total}}}$$

n_{correct} ：預測正確的測試筆數； n_{total} ：測試集總筆數 (360)。

三、訓練與評估流程

- 1. `load_digits()` 載入 1797 張 8×8 影像，攤平為 64 維像素特徵
- 2. `train_test_split(test_size=0.2, random_state=42)` : 1437 筆訓練 / 360 筆測試
- 3. `StandardScaler` : 僅以訓練集計算 mean / std , 測試集只做 transform
- 4. `SelectFromModel` + L1 Logistic Regression : 依像素重要性取前 N 個
- 5. `GridSearchCV` : 5-fold StratifiedKFold , 搜尋特徵數量與正則化強度共 9 組
- 6. 驗證特徵上限 : 選用像素數必須 ≤ 44 , 否則直接拋出錯誤中止
- 7. `joblib.dump()` 儲存整條 Pipeline (含 scaler 與 selector)
- 8. 評估程式重建相同測試集 , 載入模型輸出分類報告與混淆矩陣
- 9. 自管線取出特徵選取遮罩 , 繪製 8×8 遮罩圖

關鍵限制

測試集全程未參與任何調參，僅在最後評估時使用一次；切分種子固定為 42，繳交的評估程式才能重現完全相同的測試集，助教執行時不需重新訓練或交叉驗證即可得到一致結果。

四、模型選取結果

5-fold 交叉驗證在 9 組參數組合上的平均正確率（依排名排序）：

排名	選用像素數	分類器 C	CV 平均正確率	標準差
1	40	1.0	0.9638	0.0090
1	44	1.0	0.9638	0.0095
3	44	10.0	0.9631	0.0109
4	40	10.0	0.9617	0.0130
5	40	0.1	0.9617	0.0096
6	44	0.1	0.9610	0.0095
7	32	1.0	0.9575	0.0087
8	32	10.0	0.9520	0.0143
9	32	0.1	0.9513	0.0067


最佳組合

- selector__max_features = 40
- classifier__C = 1.0
- 交叉驗證平均正確率 = 0.9638
- 測試集正確率 = 0.9750

三組特徵數量中，40 與 44 個像素的表現相同（CV 皆為 0.9638），32 個像素明顯較差；在同分的情況下選擇像素數較少的 40 個，淘汰 24 個，符合「至少淘汰 20 個特徵、僅使用 44 個以下像素」的規定。

五、預期結果 1：特徵選取遮罩

以 8×8 遮罩圖呈現特徵選取結果，0 代表淘汰、1 代表選取，標題含選取比例 40/64 (必須在 44/64 以下)。



assignment3_feature_mask.png — 被淘汰的 24 個像素集中在影像最左、最右兩行與四個角落。這些位置在 8×8 手寫數字影像中幾乎恆為背景，對辨識沒有貢獻，顯示 L1 特徵選取確實抓到了有意義的筆畫區域。

六、預期結果 2：分類報告

測試集共 360 筆，整體正確率 (Accuracy) = 0.9750，達成 95% 門檻。


詳細分類報告 (Classification Report)

	precision	recall	f1-score	support
0	1.00	1.00	1.00	33
1	0.97	1.00	0.98	28
2	1.00	1.00	1.00	33
3	0.97	0.97	0.97	34
4	1.00	0.98	0.99	46
5	0.94	0.96	0.95	47
6	0.97	0.97	0.97	35
7	1.00	0.97	0.99	34
8	0.97	0.97	0.97	30
9	0.95	0.95	0.95	40
accuracy			0.97	360
macro avg	0.98	0.98	0.98	360
weighted avg	0.98	0.97	0.98	360

10 個類別的 f1-score 皆在 0.95 以上，macro avg 與 weighted avg 均為 0.98，顯示模型在各數字上的表現相當平均，沒有特定類別明顯落後。表現最弱的是數字 5 與 9 (f1-score 0.95)，兩者在 8 × 8 解析度下筆畫較容易混淆。

七、預期結果 2：混淆矩陣

測試集混淆矩陣；對角線為正確分類，非對角線為誤判。



assignment3_confusion_matrix.png — 360 筆測試樣本中共有 9 筆誤判，且分散於不同類別，沒有集中的系統性混淆。誤判多發生在筆畫相近的數字之間（例如 5 與 9、3 與 5、9 與 3），符合低解析度 8×8 影像的預期限制。

八、總結

本作業以 scikit-learn 建立低解析度手寫數字的多類別分類器，完成資料切分、特徵縮放、L1 特徵選取、交叉驗證模型選取與模型評估，並將最佳管線以 `joblib.dump()` 儲存供評估程式載入。

驗收項目對照

驗收項目	規定	實際結果
特徵淘汰數	≥ 20 個	24 個
使用像素數	≤ 44 個	40 個
測試集正確率	$\geq 95\%$	97.50%
測試集樣本數	約 360 筆	360 筆
模型儲存	<code>joblib.dump()</code> 管線	<code>digits_pipeline_lr.pkl</code>

主要發現

- 僅用 40 個像素 (淘汰 24 個) 即達成 97.50% 測試正確率，高於 95% 門檻
- 被淘汰的像素全部落在影像邊緣，與手寫數字的背景區域吻合
- 40 與 44 個像素的交叉驗證表現相同，顯示再多的邊緣像素並未帶來額外資訊
- 繳交的評估程式不含任何訓練或模型選取程式碼，助教可直接執行批閱

繳交內容

- `07_assignment3_eval.py`：僅載入模型並評估，不含訓練或模型選取程式碼
- `digits_pipeline_lr.pkl`：以 `joblib.dump()` 儲存的完整管線 (含預處理與模型)