Assignment #5

低解析度手寫數字多類別分類（PCA 特徵提取）

機器學習實作系列　第 10 週：特徵提取與降維

課程教授：陳慶永　　課程助教：翁宣允

姓名：陳欣怡　　學號：515661055

資料集：sklearn.datasets.load_digits()（1797 張 8×8 灰階影像）

模型：StandardScaler → PCA 特徵提取 → Logistic Regression

一、作業說明

目的

建立低解析度手寫數字 (0–9) 的多類別分類器。本次作業的實作任務與 Assignment #3 (Lecture 6) 相同，唯一的差別是把特徵選取換成特徵提取（使用 PCA）。

特徵選取與特徵提取的差別

特徵選取是從原本的 64 個像素中挑出一個子集合，被保留的欄位仍然是原始像素，可以直接指著影像說「用了哪幾格」；特徵提取則是把 64 維投影到一組全新的座標軸上，每一個新維度都是 64 個像素的線性組合，不再對應任何單一像素。

資料集：sklearn.datasets.load_digits()

- 1797 張 8 × 8 灰階（grayscale）影像
- 64 維（像素值）特徵，整數值範圍 [0, 16]
- 多類別標籤 0–9，共 10 類
- 資料直接由 scikit-learn 載入，無外部 CSV 檔

任務需求

- 以 Logistic Regression 作為分類器演算法
- 運用資料切分、特徵縮放、特徵提取 (PCA)、模型選取與模型評估
- 切分比例：80% 訓練（用於交叉驗證）、20% 測試
- 降維後的特徵空間維度 ≤ 40
- 在測試集（約 360 筆樣本）上的整體正確率（Accuracy）達 95% 以上
- 使用 joblib.dump() 將訓練好的最佳模型（指管線）儲存成檔案

二、數學觀念

1. 標準化（Z-score）

$$z = \frac{x - \mu}{\sigma}$$

PCA 以變異數大小挑選主軸，若各像素尺度不一，主軸會被數值範圍大的像素綁架，因此縮放必須排在 PCA 之前。μ、σ 僅以訓練集計算。

2. 共變異數矩陣

$$\Sigma = \frac{1}{n-1} \sum_{i=1}^{n} (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

Σ 為 64 × 64 的對稱矩陣，描述各像素之間的共變關係。

3. PCA — 特徵分解求主軸

$$\Sigma \mathbf{v}_j = \lambda_j \mathbf{v}_j$$

特徵向量 $\mathbf{v}_j$ 即主成分方向，特徵值 λ_j 為資料在該方向上的變異數。將 λ_j 由大到小排序，取前 k 個特徵向量組成投影矩陣 $\mathbf{W}$，即可把樣本降到 k 維。

4. 投影與解釋變異比例

$$\mathbf{z} = \mathbf{W}^\top \mathbf{x}$$

$$\mathrm{EVR}_j = \frac{\lambda_j}{\sum_{m=1}^{64} \lambda_m}$$

總解釋變異量為前 k 個 EVR_j 之和，代表降維後保留了原始資料多少比例的變異。

5. 多類別 Logistic Regression — Softmax

$$P(y = k \mid \mathbf{z}) = \frac{e^{\mathbf{w}_k \cdot \mathbf{z} + b_k}}{\sum_{j=0}^{9} e^{\mathbf{w}_j \cdot \mathbf{z} + b_j}}$$

分類器接到的是 PCA 投影後的 k 維向量 $\mathbf{z}$，不是原始像素。

三、訓練與評估流程

- 1. load_digits() 載入 1797 張 8 × 8 影像，攤平為 64 維像素特徵
- 2. train_test_split(test_size=0.2, random_state=42)：1437 筆訓練 / 360 筆測試
- 3. StandardScaler：僅以訓練集計算 mean / std，測試集只做 transform
- 4. PCA：在標準化後的訓練資料上求主成分，取前 n_components 個
- 5. GridSearchCV：5-fold StratifiedKFold，搜尋 n_components 與 C 共 9 組
- 6. 驗證維度上限：保留的主成分數必須 ≤ 40，否則直接拋出錯誤中止
- 7. joblib.dump() 儲存整條 Pipeline（含 scaler 與 PCA）
- 8. 評估程式重建相同測試集，載入模型輸出維度、解釋變異量與分類報告
- 9. 視覺化呈現測試集混淆矩陣
- 10. 比對預測與真實標籤找出所有誤判樣本，輸出總數並逐張繪出

關鍵限制

測試集全程未參與任何調參，僅在最後評估時使用一次；切分種子固定為 42，繳交的評估程式才能重現完全相同的測試集，助教執行時不需重新訓練或交叉驗證即可得到一致結果。

四、模型選取結果

5-fold 交叉驗證在 9 組參數組合上的平均正確率（依排名排序）：

排名	PCA 維度	分類器 C	CV 平均正確率	標準差
1	40	1.0	0.9638	0.0068
2	30	1.0	0.9576	0.0046
3	40	0.1	0.9575	0.0034
4	30	0.1	0.9541	0.0060
5	30	10.0	0.9527	0.0057
6	40	10.0	0.9520	0.0068
7	20	1.0	0.9415	0.0081
8	20	0.1	0.9388	0.0102
9	20	10.0	0.9381	0.0087

最佳組合

- pca__n_components = 40
- classifier__C = 1.0
- 交叉驗證平均正確率 = 0.9638
- 測試集正確率 = 0.9611

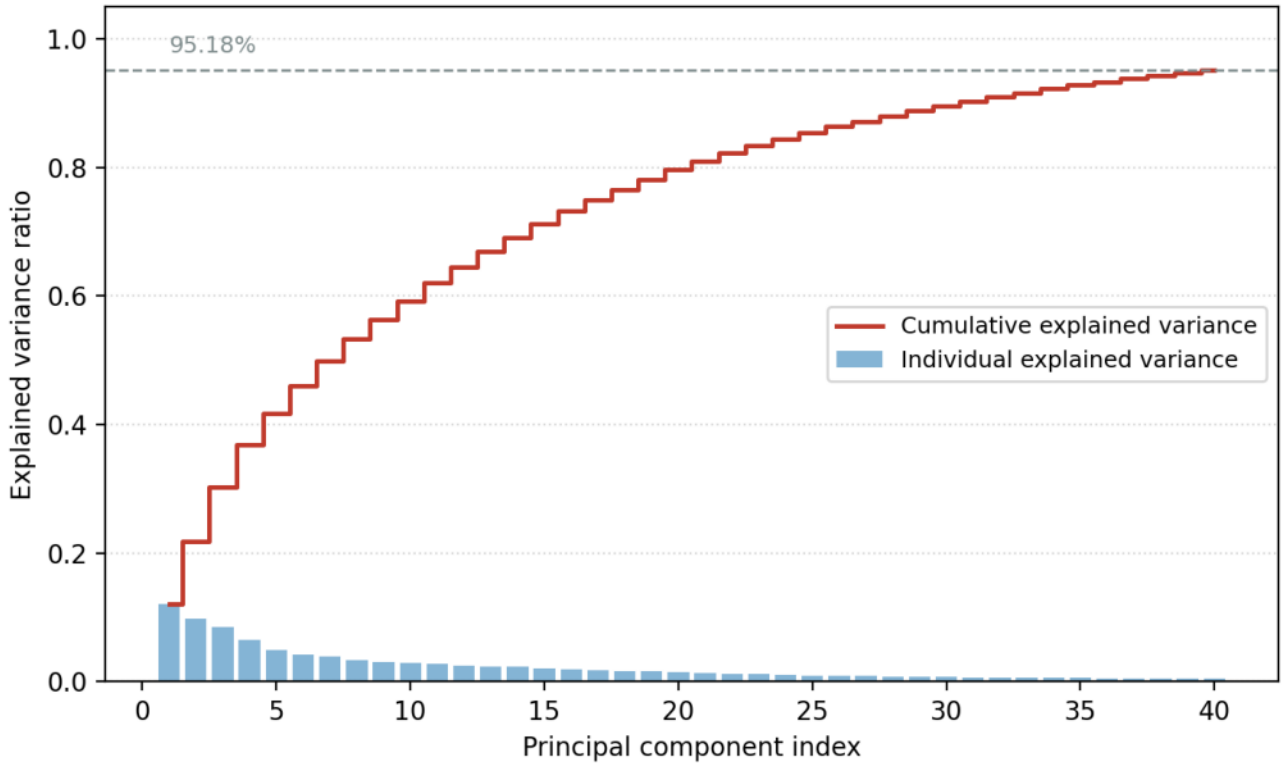
三種維度中以 40 維最佳，且剛好是作業允許的上限；維度降到 30 與 20 時交叉驗證分別掉到 0.9576 與 0.9415，顯示在這個資料集上 PCA 的維度仍是主要的效能來源（詳見第九節）。

五、預期結果 1：PCA 維度與總解釋變異量

評估程式輸出：

```
PCA 提取後的特徵維度 (n_components): 40 (從原本的 64 維降至 40 維)
特徵提取的總解釋變異量: 95.18%
```

降維後的特徵空間維度為 40，符合「必須在 40 以下」的規定；這 40 個主成分保留了原始 64 維資料 95.18% 的變異，也就是說捨棄 24 個維度只損失了 4.82% 的變異量。



assignment5_explained_variance.png — 報告補充圖（投影片未要求）。長條為各主成分的個別解釋變異比例，紅線為累積值。前幾個主成分就吃掉大部分變異，之後迅速衰減，這正是 PCA 能把 64 維壓到 40 維而幾乎不損失資訊的原因。

六、預期結果 2：分類報告

測試集共 360 筆，整體正確率（Accuracy）= 0.9611，達成 95% 門檻。

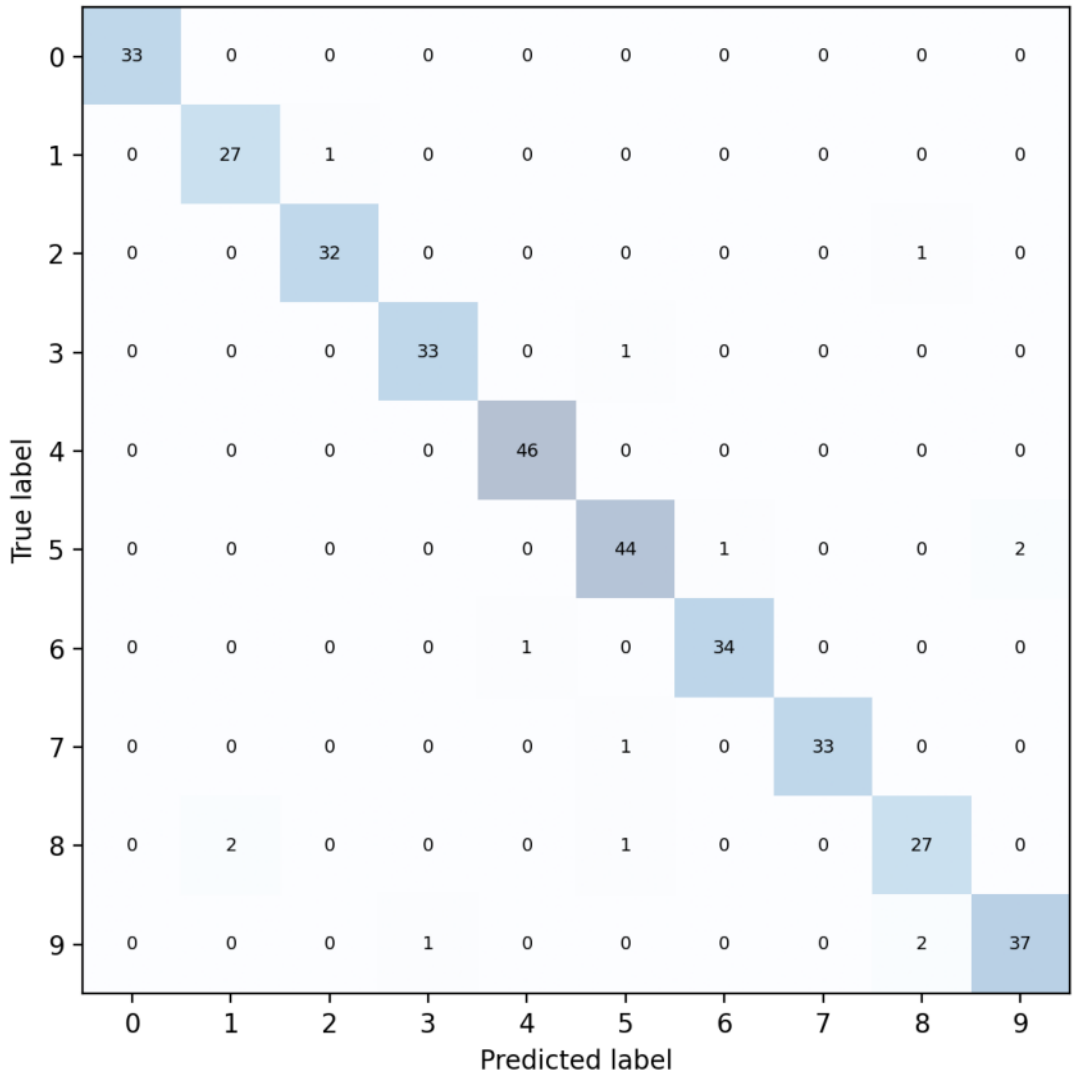
詳細分類報告（Classification Report）

	precision	recall	f1-score	support
0	1.00	1.00	1.00	33
1	0.93	0.96	0.95	28
2	0.97	0.97	0.97	33
3	0.97	0.97	0.97	34
4	0.98	1.00	0.99	46
5	0.94	0.94	0.94	47
6	0.97	0.97	0.97	35
7	1.00	0.97	0.99	34
8	0.90	0.90	0.90	30
9	0.95	0.93	0.94	40
accuracy			0.96	360
macro avg	0.96	0.96	0.96	360
weighted avg	0.96	0.96	0.96	360

10 個類別的 f1-score 皆在 0.90 以上，macro avg 與 weighted avg 均為 0.96，各數字的表現相當平均。表現最弱的是數字 8（f1-score 0.90），其次是 5 與 9（0.94），這幾個數字在 8 × 8 解析度下筆畫本就容易混淆。

七、預期結果 2：混淆矩陣

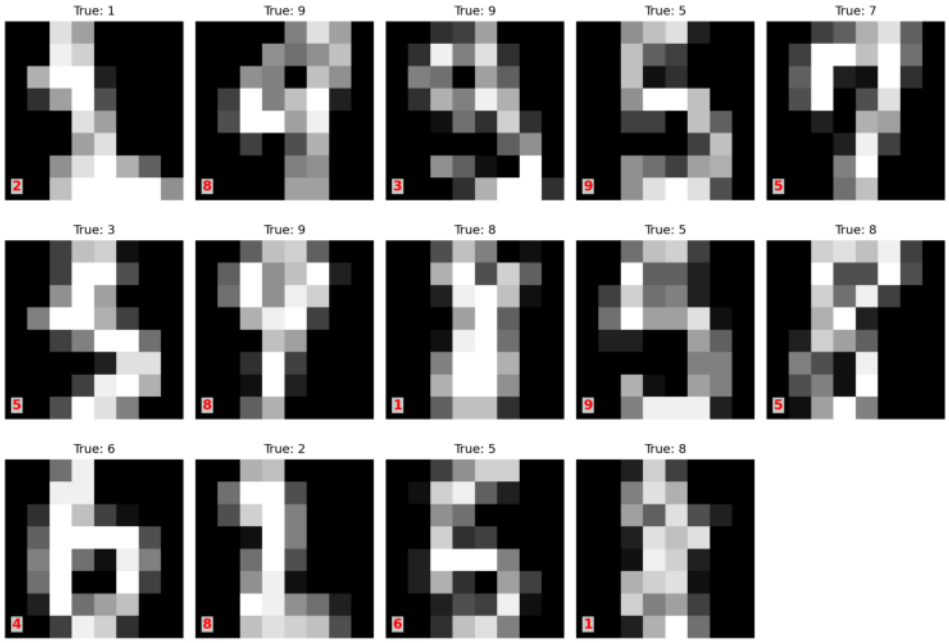
測試集混淆矩陣；對角線為正確分類，非對角線為誤判。



assignment5_confusion_matrix.png — 360 筆測試樣本中共有 14 筆誤判，分散於不同類別，沒有集中的系統性混淆。誤判多發生在筆畫相近的數字之間（例如 8 與 1、9 與 8、5 與 9），符合低解析度 8 × 8 影像的預期限制。

八、預期結果 3：誤判樣本

評估程式輸出：「測試集總共誤判了 14 張圖片。」下圖繪出所有誤判樣本：每張圖上方的 True 為真實標籤，左下角紅字為模型的預測結果。



assignment5_misclassified.png — 共 14 張，與混淆矩陣非對角線的總和一致。

九、誤判樣本與混淆矩陣對應

作業要求誤判樣本圖「必須與混淆矩陣對應」。下表逐張列出誤判樣本的真實標籤、預測結果，以及該組合在混淆矩陣中對應格子的計數。

順序	真實標籤	預測結果	混淆矩陣該格計數
1	1	2	1
2	9	8	2
3	9	3	1
4	5	9	2
5	7	5	1
6	3	5	1
7	9	8	2
8	8	1	2
9	5	9	2
10	8	5	1
11	6	4	1
12	2	8	1
13	5	6	1
14	8	1	2

十、改善空間討論（一）：降維預算

以下比較皆在訓練集（1437 筆）上以 5-fold 交叉驗證進行，測試集不參與任何設定的挑選。

維度與正確率、解釋變異量的關係

PCA 維度	CV 正確率	標準差	總解釋變異量
PCA 10 維	0.8803	± 0.0088	59.23%
PCA 20 維	0.9415	± 0.0081	79.59%
PCA 30 維	0.9576	± 0.0046	89.55%
PCA 40 維（上限）	0.9638	± 0.0068	95.18%

正確率隨維度單調上升，而且在 40 維仍未飽和——換句話說，作業的「維度 ≤ 40」在這個資料集上是真正有約束力的限制，和 Assignment #3 的特徵數量上限不同（當時放寬到 64 個像素也只多 0.4 個百分點）。原因是 PCA 的每一個維度都是全部 64 個像素的線性組合，沒有哪個維度是純粹的背景，捨棄就是實質的資訊損失。

十一、改善空間討論（二）：其他可調整項目

白化（whitening）

設定	CV 正確率	標準差
不白化（基準）	0.9638	± 0.0068
白化 whiten=True	0.9541	± 0.0046

白化把各主成分的變異數拉成 1，等於丟掉「哪個方向變異較大」這個資訊。對 Logistic Regression 而言這項資訊是有用的，因此白化後反而掉了約 1 個百分點。

分類器正則化強度

設定	CV 正確率	標準差
C = 0.1	0.9575	± 0.0034
C = 1.0（基準）	0.9638	± 0.0068
C = 10.0	0.9520	± 0.0068
C = 100.0	0.9450	± 0.0041

往兩側調整都沒有帶來提升，顯示目前的設定已接近這個模型的最佳點。

換用其他特徵提取法

提取方法	CV 正確率	標準差
PCA（基準）	0.9638	± 0.0068
Kernel PCA (RBF)	0.9388	± 0.0100
LDA（9 維上限）	0.9520	± 0.0074

RBF 核的 Kernel PCA 在相同維度下反而較差（核寬度本身又是一組需要調的超參數）；LDA 雖然是監督式降維，但最多只能投影到「類別數 − 1」= 9 維，在只有 9 維可用的情況下仍達 0.9520，可見其維度效率很高，只是天花板受限。

十二、改善空間討論（三）：真正的瓶頸與最終取捨

瓶頸仍在線性決策邊界

分類器（皆用 40 維主成分）	CV 正確率	標準差
Logistic Regression（基準）	0.9638	± 0.0068
RBF SVM	0.9791	± 0.0044

在完全相同的 40 維主成分上改用 RBF 核的 SVM，CV 提升約 1.5 個百分點，幅度大於前面所有調整。這與 Assignment #3 的結論一致：限制效能的是 Logistic Regression 的線性決策邊界，而非特徵的表示方式。本作業指定使用 Logistic Regression，故此組僅作為討論對照。

特徵提取 vs 特徵選取：與 Assignment #3 的對照

作業	特徵處理	維度	CV 正確率	測試集正確率
#3	L1 特徵選取	40 個原始像素	0.9638	0.9750
#5	PCA 特徵提取	40 維主成分	0.9638	0.9611

兩者的交叉驗證正確率完全相同（0.9638），測試集上特徵選取則多對了 5 筆。360 筆的測試集中 5 筆約等於 1.4 個百分點，和交叉驗證的標準差（±0.007）屬同一量級，不足以判定何者較優。真正的差別在性質而非分數：特徵選取保留了原始像素、可以直接指出用了哪幾格，特徵提取則把資訊壓縮進線性組合，可解釋性較低，但不需要「某些欄位恰好沒有資訊」這個前提，在特徵高度相關的資料上更通用。

最終決定

維持以交叉驗證選出的設定（40 維主成分、C = 1.0）不變。上述所有替代方案要不是在交叉驗證上較差，就是違反作業指定的演算法；而唯一在 CV 上較佳的 RBF SVM 並非本作業允許的分類器。

十三、總結

本作業以 scikit-learn 建立低解析度手寫數字的多類別分類器，將 Assignment #3 的特徵選取換成 PCA 特徵提取，完成資料切分、特徵縮放、特徵提取、交叉驗證模型選取與模型評估，並將最佳管線以 joblib.dump() 儲存供評估程式載入。

驗收項目對照

驗收項目	規定	實際結果
分類器演算法	Logistic Regression	Logistic Regression
特徵提取	PCA	PCA，64 維 → 40 維
降維後維度	≤ 40	40
總解釋變異量	須輸出	95.18%
測試集正確率	≥ 95%	96.11%
測試集樣本數	約 360 筆	360 筆
誤判樣本	總數與圖須對應混淆矩陣	14 張，一致
模型儲存	joblib.dump() 管線	digits_pipeline_lr_pca.pkl

主要發現

- 40 維主成分保留 95.18% 的變異，測試集正確率 96.11%，高於 95% 門檻
- 360 筆測試樣本誤判 14 張，分散在不同數字組合，無系統性混淆
- 與 Assignment #3 相比，CV 正確率完全相同（0.9638），測試集差 5 筆、屬標準差量級
- PCA 維度在 40 維仍未飽和，維度上限是真正有約束力的限制（與特徵選取不同）
- 白化、Kernel PCA 都讓表現變差；改用 RBF SVM 可達 0.9791，瓶頸在線性決策邊界
- 繳交的評估程式不含任何訓練或模型選取程式碼，助教可直接執行批閱

繳交內容

- 10_assignment5_eval.py：僅載入模型並評估，不含訓練或模型選取程式碼
- digits_pipeline_lr_pca.pkl：以 joblib.dump() 儲存的完整管線（含預處理與 PCA）